Selbstüberwachtes Training für die Datierung von Dokumentbildern

Dmytro Pahuba
dmytro.pahuba@tu-dortmund.de

24.6.2025

Zusammenfassung

In dieser Arbeit wird die Anwendung selbstüberwachter Lernverfahren für die automatisierte Datierung historischer Dokumentenbilder untersucht. Während traditionelle überwachte Methoden durch begrenzte annotierte Datensätze eingeschränkt sind, ermöglicht selbstüberwachtes Vortraining die Nutzung großer Mengen nicht-annotierter historischer Manuskripte. Die Arbeit untersucht selbstüberwachte Lernverfahren für die zeitliche Einordnung von Dokumenten, mit Fokus auf das AttMask-Framework von Christlein et al. [2024] als primären Ansatz durch Transfer Learning von Writer Identification zu Document Dating.

1 Motivation

Die automatische Datierung von historischen Dokumenten hat in der Geschichtsforschung eine hohe Relevanz. Traditionelle Ansätze basieren auf überwachten Lernverfahren, die große Mengen bereits datierter Dokumente zum Lernen benötigen. Oft sind die gelabelten Daten für historische Dokumente nur begrenzt verfügbar, weil die manuelle Datierng durch Experten zeitaufwändig und kostspielig ist. Die Experten benötigen jahrelange Ausbildung, um Schriftstile zeitlich einzuordnen, und selbst dann variieren Einschät-zungen oft um 50-100 Jahre [Schomaker et al., 2007]. Gleichzeitig wächst die Anzahl digitalisierter Dokumentensammlungen exponentiell, während die manuelle Expertise begrenzt bleibt. Der KERTAS-Datensatz umfasst etwa 2000 arabische Manuskripte [Hassaïne et al., 2013], die Medieval Paleographic Scale etwa 1000 Dokumente aus dem Zeitraum 1300-1550 [University of Groningen, 2019]. Für Deep Learning sind das problematisch kleine Zahlen. Selbstüberwachtes Lernen könnte diese Limitation umgehen. Archive enthalten Millionen nicht-annotierter Dokumente, die für SSL-Training genutzt werden könnten. Das AttMask-Framework von Christlein et al. [2024] erreichte 83.1% mAP

auf Historical-WI und 95.0% mAP auf HisIR19 Datensätzen für Writer Retrieval. Diese Erfolge legen nahe, dass SSL-basierte Repräsentationen auch für temporale Charakteristika von Dokumenten relevant sein könnten.

2 Verwandte Arbeiten

2.1 Traditionelle Dokumentdatierung

Frühe Arbeiten konzentrierten sich auf handcrafted Features wie Strich- und Konturanalyse [Kleber et al., 2013]. He et al. [2014] verwendeten Gabor-Filter und Texturmerkmale für chinesische Dokumente, erreichten aber nur moderate Genauigkeit. Ghosh et al. [2016] kombinierten multiple Merkmalsextraktoren mit Support Vector Machines für Manuskripte des 9.-18. Jahrhunderts.

2.2 Deep Learning Ansätze

Wahlberg et al. [2016] waren Pioniere beim Einsatz von CNNs für historische Dokumentdatierung und erreichten auf schwedischen Urkunden Mean Absolute Errors von 18.9 Jahren. Mohammed et al. [2020] entwickelten hierarchische Feature-Fusion-Methoden und erreichten 22 Jahren MAE auf ICDAR-Datensätzen. Aktuelle Ansätze nutzen Vision Transformers [Dosovitskiy et al., 2021]. Das DiT-System [Li et al., 2022] erreichte 92.69% Accuracy bei Dokumentklassifikation durch Masked Image Modeling auf 42 Millionen unlabeled Dokumenten. Allerdings konzentriert sich DiT auf moderne Dokumente, nicht historische Manuskripte.

2.3 Writer Identification und SSL

Die Schreibererkennung hat erhebliche Fortschritte gemacht [Christlein et al., 2017]. Christlein et al. [2024] erreichten mit selbstüberwachten Vision Transformers bahnbrechende Ergebnisse: 83.1 Prozente mAP auf Historical-WI und 95.0 Prozente mAP auf HisIR19 Datensätzen. Diese Erfolge sind relevant, da Schreibstil und Zeitepoche korrelieren.

2.4 Selbstüberwachtes Lernen für Dokumente

SSL-Methoden haben in Computer Vision durchschlagenden Erfolg gezeigt. DINO lernt semantische Repräsentationen ohne Labels, Masked Autoencoders rekonstruieren verdeckte Bildteile. Für Dokumente zeigt SelfDocSeg [Kumar et al., 2023] vielversprechende Ansätze für Dokumentsegmentierung. Die Forschungslücke liegt in der Anwendung dieser modernen SSL-Techniken speziell für historische Dokumentdatierung. Bisherige Arbeiten nutzen entweder überwachtes Lernen mit kleinen Datensätzen oder SSL für andere Aufgaben.

3 Methodik

3.1 Datenaufbereitung

Die Arbeit nutzt den CLAMM ICDAR-2017-Datensatz [CLAMM, 2017] mit 6,540+ Bildern aus 1,100 Jahren (500-1600 CE) und 12 paläographischen Schriftklassen. Zusätzlich wird der CATMuS

Medieval-Datensatz eingesetzt. Vorverarbeitung umfasst Normalisierung auf 256×256 Pixel, Graustufenkonvertierung und Augmen-tierung durch Rotation, Skalierung und Rauscheinführung. Kritisch ist die tem-porale Aufteilung der Datensätze zur Vermeidung von Informationsleckage.

3.2 SSL-Architektur

Das System nutzt AttMask von Christlein et al. [2024], das DINO Self-Distillation mit attention-guided Masking kombiniert. Der Teacher identifiziert wichtige Bildregionen über Self-Attention Maps, die dann beim Student maskiert werden. Features werden über VLAD-Aggregation von Foreground-Patches zu globalen Dokumentrepräsentationen zusammengefasst. Die kritische Frage bleibt, ob Writer-ID-Features überhaupt für Document Dating geeignet sind. Das Framework lernt individuelle Schreibereigenschaften, während Dating temporale Stilentwicklungen erfassen muss.

3.3 Transfer Learning Ansatz

Das vortrainierte WID-Small Modell wird für Dating adaptiert. Der Ansatz erfolgt in drei Stufen:

1. **Lineare Evaluation:** Die gelernten Features werden mit einem linearen Klassifikator evaluiert
2. **k-NN Evaluation:** k-Nearest-Neighbor (k=20) ohne Hyperparameter-Tuning
3. **Fine-tuning:** Das Modell wird für Writer-ID zu Dating Transfer finegetunet

Das Modell lernt zunächst, gleiche Schreiber zu gruppieren. Diese Fähigkeit wird dann für temporale Gruppierung adaptiert, da Schreibstil und Zeitepoche korrelieren. Multi-Task Learning optimiert gleichzeitig Writer ID und Dating Loss.

3.4 Baseline

Als Baseline dient ein überwachtes ResNet-50-basiertes System [He et al., 2016] mit Regression-Head für Jahresvorhersage. Der Loss kombiniert L1-Loss für Genauigkeit mit Ranking-Loss für ordinale Beziehungen:

$$\mathcal{L} = \mathcal{L}_{L1} + \lambda \mathcal{L}_{ranking} \tag{1}$$

3.5 Evaluation

Hauptmetrik ist Mean Absolute Error (MAE) in Jahren:

$$MAE = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i| \tag{2}$$

Zusätzliche Metriken umfassen Root Mean Square Error (RMSE) und Accuracy@k (Vorhersage innerhalb k Jahre). Validierung erfolgt durch temporale Kreuzvalidierung zur Vermeidung von Data Leckage.

4 Experimente

4.1 Datensätze

- **CLAMM ICDAR-2017:** 6,540+ Bilder, 1,100 Jahre Zeitspanne, 12

Schriftklassen

- **CATMuS Medieval:** Mittelalterliche Handschriften mit konsistenten Annotationen

4.2 SSL-Pretraining

Vision Transformer wird auf kombinierten unlabeled Daten für 100 Epochen vortrainiert. VLAD-Aggregation mit 100 Clustern aggregiert Foreground-Patches zu globalen Dokumentrepräsentationen. Temperatur-Scheduling von 0.04 zu 0.07 im DINO-Framework.

4.3 Transfer Learning Pipeline

1. SSL-Pretraining auf unlabeled Dokumentenbildern
2. Lineare Evaluation der extrahierten Features
3. k-NN Evaluation ohne Hyperparameter-Tuning
4. Fine-tuning für Writer-ID zu Dating Transfer
5. Vergleich mit überwachter ResNet-50 Baseline

4.4 Ablationsstudien

- Einfluss verschiedener Masking-Ratios (40-75%)
- VLAD-Clusterzahl (50, 100, 200)
- Foreground-Threshold für Patch-Selektion
- Vergleich flat encoding vs. hierarchische Ansätze
- Augmentierungsstrategien: geometrische vs. morphologische Transformationen

Literatur

Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., and Joulin, A. (2021). Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 9650–9660.

Christlein, V., Kleber, F., Fiel, S., Maier, A., and Angelopoulou, E. (2017). Writer identification using GMM supervectors and exemplar-SVMs. *Pattern Recognition*, 63:258–267.

Christlein, V., Raven, T., Matei, A., and Fink, G. A. (2024). Self-supervised vision transformers for writer retrieval. *ArXiv preprint arXiv:2409.00751*.

CLAMM (2017). Classification of medieval handwritings in latin script. `https://clamm.irht.cnrs.fr/icdar-2017/`.

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*.

Ghosh, S., Valveny, E., and Bagdanov, A. D. (2016). Image-based historical manuscript dating using contour and

stroke fragments. *Pattern Recognition*, 58:29–42.

Hassaïne, A., Al Maadeed, S., Aljaam, J., and Jaoua, A. (2013). KERTAS: dataset for automatic dating of ancient Arabic manuscripts. *International Journal on Document Analysis and Recognition*, 16(3):283–290.

He, S., Wiering, M., and Schomaker, L. (2014). Towards style-based dating of historical documents. In *International Conference on Frontiers in Handwriting Recognition*, pages 265–270.

He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778.

He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R. (2022). Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16000–16009.

Kleber, F., Fiel, S., Diem, M., and Sablatnig, R. (2013). CVL-Database: An off-line database for writer retrieval, writer identification and word spotting. In *International Conference on Document Analysis and Recognition*, pages 560–564.

Kumar, A., Chandra, S., Bhattacharya, A., and Jawahar, C. V. (2023). SelfDocSeg: A self-supervised vision-based approach towards document segmentation. In *International Conference on Document Analysis and Recognition*, pages 387–402.

Li, J., Xu, Y., Lv, T., Cui, L., Zhang, C., and Wei, F. (2022). DiT: Self-supervised pre-training for document image transformer. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 1530–1537.

Mohammed, H., Märgner, V., and Fink, G. A. (2020). Deep learning-based approach for historical manuscript dating. In *International Conference on Pattern Recognition*, pages 7346–7353.

Schomaker, L., Franke, K., and Bulacu, M. (2007). Automatic writer identification using connected-component contours and edge-based features of uppercase western script. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 29(5):787–798.

University of Groningen (2019). MPS - Medieval Paleographic Scale. Research Portal, doi:10.34894/NJRXVW.

Wahlberg, F., Mårtensson, L., and Brun, A. (2016). Historical manuscript production date estimation using deep convolutional neural networks. In *International Conference on Frontiers in Handwriting Recognition*, pages 205–210.